

Solución de la Evaluación

Curso 2021

Ejercicio 1

- a) Se debe aplicar la extensión para el manejo de atributos continuos. El primer paso es discretizar el atributo “Dificultad”. Para esto ordenamos las instancias según este atributo:

#	Dificultad	Apto para niños
4	24	Apto
1	30	No apto
3	32	Apto
2	46	Apto
5	70	No apto

Consideramos entonces tres puntos de corte donde cambia el valor del concepto objetivo: 27, 31 y 58. Buscamos el punto que maximice la ganancia y, por lo tanto, el que minimice la siguiente ecuación:

$$\sum \text{Val}(A) (|S_v|/|S|) \text{Entropía}(S_v)$$

Resultados:

- Partición en 27: $1/5 * 0 + 4/5 * 1 = 4/5 = 0.8$
- Partición en 31: $2/5 * 1 + 3/5 * (2/3 * \log(2/3) + 1/3 * \log(1/3)) \approx 0.95$
- Partición en 58: $4/5 * (3/4 * \log(3/4) + 1/4 * \log(1/4)) + 1/5 * 0 \approx 0.65$

Elegimos entonces la partición en 58, y por lo tanto el conjunto de datos queda de la siguiente forma:

#	Género	¿Difícil?	Apto para niños
1	Estrategia	No	No apto
2	Aventura	No	Apto
3	Estrategia	No	Apto
4	Cartas	No	Apto
5	Cartas	Sí	No apto

Ahora que todos los atributos son discretos, podemos aplicar el algoritmo ID3 original. Buscamos el atributo que minimice la ecuación antes mencionada.

- Valor para “¿Difícil?”: 0.65 (se calculó antes)
- Valor para “Género”: $1/5 * 0 + 2/5 * 1 + 2/5 * 1 = 0.8$

Se elige entonces el atributo “¿Difícil?”.

- Rama ¿Difícil?=Sí

Todas las instancias son no aptas para niños, así que ponemos una hoja con valor “No apto”.

- Rama ¿Difícil?=No

El conjunto no es homogéneo, así que hay que elegir otro atributo. Como solo queda “Género”, se elige este atributo.

- Rama Género=Estrategia

Tenemos una instancia que es apta para niños y una que no, pero no hay atributos. Se genera una hoja con el valor más frecuente del conjunto. Como hay empate, se elige un valor entre los dos al azar: “No Apto”.


- Rama Género=Aventura

Todas las instancias son aptas para niños, así que ponemos una hoja con valor “Apto”.

- Rama Género=Cartas

Todas las instancias son aptas para niños, así que ponemos una hoja con valor “Apto”.

Árbol resultante:



b) Ver teórico.

c) Ver teórico.

d) Para aplicar KNN hay que normalizar los atributos numéricos y definir una función de distancia para aquellos que no lo son. Para normalizar el atributo “Dificultad”, basta con dividir sus valores entre 100. En el caso del atributo “Género”, definimos la distancia de la siguiente forma:

- $g(x,x) = 0$
- $g(x,y) = 1$ si $x \neq y$

El conjunto de datos queda entonces así:

#	Género	Dificultad	Apto para niños
1	Estrategia	0.30	No apto
2	Aventura	0.45	Apto
3	Estrategia	0.32	?
4	Cartas	0.25	Apto
5	Cartas	0.70	No apto

Calculamos las distancias de la instancia #3 a las demás:

Distancia con instancia #1: $0 + 0.02 = 0.02$

Distancia con instancia #2: $1 + 0.13 = 1.13$

Distancia con instancia #4: $1 + 0.07 = 1.07$

Distancia con instancia #5: $1 + 0.38 = 1.38$

Se utilizan las instancias #1, #2 y #4 para clasificar a #3, dado que son las tres más cercanas. Como la mayoría de ellas (2 de 3) son aptas para niños, entonces la instancia #3 se clasifica como apta para niños.

Ejercicio 2

- a) Notamos la hipótesis "dopping" como h , "no dopping" como $\neg h$, test positivo como $\oplus$ y test negativo como $\ominus$. Queremos calcular $P(h|\oplus)$.

Tenemos que:

- i. $P(h) = 0,01 \Rightarrow P(\neg h) = 0,99$
- ii. $P(\oplus|h) = 0,9 \Rightarrow P(\ominus|h) = 0,1$
- iii. $P(\ominus|\neg h) = 0,85 \Rightarrow P(\oplus|\neg h) = 0,15$

Utilizando Bayes:

$$P(h|\oplus) * P(\oplus) = P(\oplus|h) * P(h)$$

Calculamos el valor $P(\oplus)$ que falta:

$$\begin{aligned} P(\oplus) &= P(\oplus|h) * P(h) + P(\oplus|\neg h) * P(\neg h) \\ &= 0,9 * 0,01 + 0,15 * 0,99 \\ &= 0,1575 \end{aligned}$$

Despejando la fórmula se tiene que:

$$\begin{aligned} P(h|\oplus) &= P(\oplus|h) * P(h) * P(\oplus)^{-1} \\ &= 0,9 * 0,01 * 0,1575^{-1} \\ &= \mathbf{0,057} \end{aligned}$$

- b) Queremos calcular $P(h|\ominus\oplus)$ y $P(\neg h|\ominus\oplus)$

Utilizando Bayes:

$$P(h|\ominus\oplus) = P(\ominus\oplus|h) * P(h) * P(\ominus\oplus)^{-1}$$

Como los test son independientes se cumplen:

$$\begin{aligned} P(\ominus\oplus|h) &= P(\ominus|h) * P(\oplus|h) \\ &= 0,9 * 0,1 \\ &= 0,09 \end{aligned}$$

$$\begin{aligned} P(\ominus\oplus|\neg h) &= P(\ominus|\neg h) * P(\oplus|\neg h) \\ &= 0,85 * 0,15 \\ &= 0,1275 \end{aligned}$$

Además:

$$\begin{aligned} P(\ominus\oplus) &= P(\ominus\oplus|h) * P(h) + P(\ominus\oplus|\neg h) * P(\neg h) \\ &= 0,09 * 0,01 + 0,1275 * 0,99 \\ &= 0,127125 \end{aligned}$$

Luego:

$$\begin{aligned} P(h|\ominus\oplus) &= 0,09 * 0,01 * 0,127125^{-1} \\ &= \mathbf{0,007} \end{aligned}$$

$$\begin{aligned} P(\neg h|\ominus\oplus) &= 1 - P(h|\ominus\oplus) \\ &= \mathbf{0,993} \end{aligned}$$

b)

i. **Falso.** Las redes neuronales, por su, en general, número grande de parámetros, no son adecuadas para cuando se dispone de pocos datos.

ii. **Falso.** La función de costo depende solamente de las unidades de salida.

iii. **Falso.** Se puede estar sobreajustando y tener un error muy bajo en el conjunto de entrenamiento, y mucho más alto en instancias nuevas.

iv. **Falso.** Cambiar los conjuntos de entrenamiento y evaluación podría mejorar la medida (por azar), pero obviamente no cambia la performance del clasificador.

v. **Verdadero.** Surge de la propia definición.

Ejercicio 3

a)

- Como no podemos asumir un valor para sexo para Sam, utilizamos *one-hot-encoding* con tres categorías: es_femenino, es_masculino, no_se_conoce (una alternativa sería utilizar valores entre 0 y 1, pero eso podría sugerir un orden).
- El atributo Edad lo escalamos para que el máximo sea 1 y el mínimo 0
- Para las tres categorías en Minecraft asignamos A -> 1, B -> 0.5, C->0

El conjunto de datos queda así

Id	es_femenino	es_masc	no_se_conoce	edad	nivel_minecraft
Ana	1	0	0	0.09	1
Luis	0	1	0	0.82	0
Pedro	0	1	0	1	0
María	1	0	0	0	0.5
Sam	0	0	1	0.09	1

b) Centroides iniciales:

c1 (Ana): $\langle 1, 0, 0, 0.09, 1 \rangle$ y c2 (Luis): $\langle 0, 1, 0, 0.82, 0 \rangle$

Iteración 1: Calculo distancia de cada punto a ambos centroides y asigno el centroide más cercano.

$d(\text{Ana}, c1)$: 0 -> Ana va (trivialmente) al clúster 1

$d(\text{Luis}, c2)$: 0 -> Luis va (trivialmente) al clúster 2

$d(\text{Pedro}, c1) = 1 + 1 + 0 + (1 - 0.09)^2 + 1 = 3.82$

$d(\text{Pedro}, c2) = 0 + 0 + 0 + 1 + 0 = 1$

Pedro va al clúster 2

$d(\text{Maria}, c1) = 0 + 0 + 0 + 0.09^2 + 0.5^2 = 0.26$

$d(\text{Maria}, c2) = 1 + 1 + 0 + 0.82^2 + 0.5^2 = 2.92$

María va al clúster 1

$d(\text{Sam}, c1) = 1 + 0 + 1 + 0 + 0 = 2$

$d(\text{Sam}, c2) = 0 + 1 + 1 + (0.09 - 0.82)^2 + 1 = 3.53$

Sam va al clúster 1

Quedan dos clústeres: $\langle \text{Ana}, \text{María}, \text{Sam} \rangle$ y $\langle \text{Luis}, \text{Pedro} \rangle$.

Recalculamos los centroides:

$$\begin{aligned}c1' &= (\text{Ana} + \text{María} + \text{Sam})/3 = \langle 1,0,0,0.09,1 \rangle / 3 + \langle 1,0,0,0,0.5 \rangle / 3 + \langle 0,0,1,0.09,1 \rangle / 3 \\ &= \langle 0.67,0,0.33,0.06,0.83 \rangle\end{aligned}$$

$$c2' = (\text{Pedro} + \text{Luis})/2 = \langle 0,1,0,0.91,0 \rangle$$

Iteración 2: en esta iteración todas las instancias quedan en el mismo clúster en el que estaban, por lo que los clústeres definitivos son los que se obtuvieron en la iteración 1.

- c) Sam queda en el clúster junto con María y Ana, debido a que su edad es más cercana y su nivel en Minecraft también (los valores para la distancia de los atributos vinculados al sexo dan iguales).

Ejercicio 4

a)

Q_0			Q_1			Q_2		
	80			80	64		100	64
	80	80		80	100		80	100
200			200			200	64	
100		80	100		80	100	80	
80	200	80	80	200	80	80	64	80
	40	100		40	160	160	40	64
				64				

b) El algoritmo no convergió aún: basta ver las discrepancias de la función Q_2 en estados adyacentes. Por ejemplo, la transición de (3,3) a (3,2) no puede tener un valor de 160 cuando el máximo de Q_2 en (3,2) es de 64.

c)

Exploración			Explotación		
●	←	←			
				→	●
		↓		↑	←

d)

Q_0			Q_1			Q_2		
	80			80	80		100	80
	80	80		80	100		80	100
200			200			200	80	
100		80	100		80	100	80	
80	200	80	80	200	80	80	64	80
	40	100		40	160	51	40	160
				64			64	64

e)

V^*			Q			π^*		
0	100	100	0	64	64	●	←	↓
			0	100	80			
				64	100			
64	80	0	0	80		→	↑	●
			0	64	51			
			51	64	0			
64	80	80	51	64	0	←	↓	↓
			64	64	51			
			0	80	80			