

Solución de la evaluación

Curso 2023

Ejercicio 1

a)

$$V^*(0) = 0$$

$$V^*(1) = 5$$

$$V^*(n+2) = \gamma V(n+1) - 1$$

$((5\gamma-1)\gamma-1)\gamma-1$	$(5\gamma-1)\gamma-1$	$5\gamma-1$	5	0
---------------------------------	-----------------------	-------------	---	---

b) $Q(1, \leftarrow) = r(1, \leftarrow) + \gamma V^*(2) = -1 + \gamma (5\gamma - 1) = 5\gamma^2 - \gamma - 1$

c) Ver teórico.

Ejercicio 2

Ver teórico.

Ejercicio 3

- a) El atributo peso es numérico y tiene valores faltantes. Ver teórico por los problemas que causa a ID3 y cómo se los soluciona.
- b) Como el conjunto de atributos no es vacío y el conjunto de entrenamiento no es homogéneo, debo seleccionar un atributo.

Busco aquel atributo T que maximice la ganancia $G(S,T)$, o sea, minimice la entropía relativa del conjunto: $\sum_{v \in \text{Val}(T)} (|S_v|/|S|) \text{Entropía}(S_v)$

Atributo Color:

$$\begin{aligned} &= 2/5 \text{Entropía}(S_{\text{amarillo}}) + 3/5 \text{Entropía}(S_{\text{rojo}}) \\ &= 2/5 [-0/2 \log 0/2 - 2/2 \log 2/2] + 3/5 [-2/3 \log 2/3 - 1/3 \log 1/3] \\ &= 2/5 \cdot 0 + 3/5 \cdot 0,91 = 0,55 \end{aligned}$$

Atributo Tamaño:

$$\begin{aligned} &= 2/5 \text{Entropía}(S_{\text{grande}}) + 2/5 \text{Entropía}(S_{\text{mediano}}) + 1/5 \text{Entropía}(S_{\text{pequeño}}) \\ &= 2/5 [-1/2 \log 1/2 - 1/2 \log 1/2] + 2/5 [-1/2 \log 1/2 - 1/2 \log 1/2] + 1/5 [-1/1 \log 1/1 - 0/1 \log 0/1] \\ &= 2/5 \cdot 1 + 2/5 \cdot 1 + 1/5 \cdot 0 = 4/5 = 0,80 \end{aligned}$$

Atributo Mes:

$$\begin{aligned} &= 2/5 \text{Entropía}(S_{\text{octubre}}) + 3/5 \text{Entropía}(S_{\text{noviembre}}) \\ &= 2/5 [-1/2 \log 1/2 - 1/2 \log 1/2] + 3/5 [-2/3 \log 2/3 - 1/3 \log 1/3] \\ &= 2/5 \cdot 1 + 3/5 \cdot 0,91 = 0,95 \end{aligned}$$

Se elige, entonces, al atributo Color y se genera una rama por cada uno de sus posibles valores:

- Color = rojo

Se llama recursivamente con los atributos {Tamaño, Mes} y los ejemplos {#1, #3, #4}.

- Color = amarillo

Se llama recursivamente con los atributos {Tamaño, Mes} y los ejemplos {#2, #5}.

$$c) \text{NB}(\langle a_1, a_2, a_3 \rangle) = \operatorname{argmax}_{v \in \{\text{buena}, \text{mala}\}} P(\text{calidad}=v) \prod P(\text{atributo}_i=a_i \mid \text{calidad}=v)$$

$$P(\text{rojo}|\text{buena}).P(\text{grande}|\text{buena}).P(\text{octubre}|\text{buena}).P(\text{buena}) = 1/3.1/3.1/3.3/5 = 1/45$$

$$P(\text{rojo}|\text{mala}).P(\text{grande}|\text{mala}).P(\text{octubre}|\text{mala}).P(\text{mala}) = 1.1/2.1/2.2/5 = 1/10$$

Luego, $\text{NB}(\langle \text{rojo}, \text{grande}, \text{octubre} \rangle) = \text{Mala}$

d) Considero L2 para la distancia entre instancias y $(1 - \delta_k)$ para los atributos:

#	Color	Tamaño	Mes	Calidad	Dist. ²
1	rojo	pequeño	octubre	Buena	1
2	amarillo	grande	noviembre	Buena	2
3	rojo	mediano	octubre	Mala	1
4	rojo	grande	noviembre	Mala	1
5	amarillo	mediano	noviembre	Buena	3

Las tres instancias más cercanas son #1 (buena), #3 (mala) y #4 (mala), luego:

$$3\text{-NN}(\langle \text{rojo}, \text{grande}, \text{octubre} \rangle) = \text{Mala}$$

e)

$$P = \#VP_{\text{Buena}} / \# \text{Clasificadas Buena} = \#VP_{\text{Buena}} / (\#VP_{\text{Buena}} + \#FP_{\text{Buena}}) = 1/3$$

$$R = \#VP_{\text{Buena}} / \# \text{Buena} = \#VP_{\text{Buena}} / (\#VP_{\text{Buena}} + \#FN_{\text{Buena}}) = 1/2$$

Ejercicio 4

a) Por el comportamiento descrito, la red está sobreajustando a los datos de entrenamiento, por lo que las estrategias deberían apuntar a reducir ese sobreajuste.

i. Aumentar el conjunto de entrenamiento con nuevos ejemplos: es válido. Es la forma más directa de mejorar la performance, aunque en general es costosa.

ii. Aplicar algún tipo de aumento de datos (data augmentation). También es válido, al tener más ejemplo se esperaría que el modelo generalizara mejor.

iii. Reducir el conjunto de validación y usar los ejemplos para entrenar. Aunque esto podría mejorar la performance (igual que el primer caso), reducir el conjunto de validación hace que la medida obtenida tenga más varianza, y por lo tanto no sería una estrategia válida, en general.

iv. Aumentar el número de iteraciones. Esto aumentaría muy probablemente el sobreajuste, por lo que no es válido.

v. Usar dropout. Válido, el dropout es una técnica típica de regularización.

vi. Reducir la tasa de aprendizaje. En general, reducir la tasa de aprendizaje lo que hace es ser más sensible a mínimos locales, por lo que es probable que empeore el problema.

b)

$$i. W(2) \in \mathbb{R}^{32 \times 784}, b(2) \in \mathbb{R}^{32}, W(3) \in \mathbb{R}^{16 \times 32}, b(3) \in \mathbb{R}^{16}, W(4) \in \mathbb{R}^{3 \times 16}, b(4) \in \mathbb{R}^3$$

$$ii. (32 \times 784) + 32 + (16 \times 32) + 16 + (3 \times 16) + 3 = 25699$$

$$iii. a(2) = g(W(2)a(1) + b(2)) \text{ siendo } g \text{ la función de activación de la red}$$

iv. No. La regularización se aplica a la función de pérdida para intentar mejorar el aprendizaje, no modifica la arquitectura de la red, y por lo tanto no cambia la cantidad de parámetros.