

Solución de la evaluación

Curso 2024

Ejercicio 1

- i. **Verdadero.** D no tienen ruido, luego c es consistente con D , y como c pertenece a H , pertenece también a $VS_{H,D}$. Luego $c(x)$ es positivo.
- ii. **Falso.** Que todas las hipótesis de $G_{H,D}$ clasifiquen a x como positivo, no implica que todas las hipótesis de $VS_{H,D}$ lo hagan (ver ejemplo del teórico). Basta tomar como concepto objetivo una de estas otras hipótesis como contraejemplo.
- iii. **Falso.** Al ajustar el modelo a la localidad del dato de consulta, el algoritmo puede ajustarse más a los datos. Para una regresión lineal de un conjunto de datos (x_i, y_i) , un algoritmo ansioso ajustará una única recta a todo el conjunto de datos, mientras que uno perezoso ajustará una basado en cada consulta, generando un modelo de los datos más expresivo o complejo.
- iv. **Verdadero.** Los algoritmos perezosos difieren la mayor parte del costo computacional a la etapa de clasificación.
- v. **Falso.** La etapa de clasificación de los algoritmos perezosos suele incurrir la mayor parte del costo computacional. En k -nn, por ejemplo, puede implicar encontrar los puntos más cercanos al de consulta y ajustar un modelo local a estos.
- vi. **Verdadero.** Los algoritmos perezosos no derivan un modelo global de todo el conjunto de datos, evitando tener que reentrenar este modelo cuando se agregan nuevos datos al conjunto de entrenamiento.
- vii. **Falso.** Lo que se busca son los valores de los parámetros de la red que minimizan la función de pérdida.
- viii. **Falso.** Las funciones de pérdida en redes neuronales no son en general convexas, y por lo tanto podría converger a un mínimo local.
- ix. **Verdadero.** Ver teórico.

Ejercicio 2

$$f(x) = x^2 - 10x$$

$$f'(x) = 2x - 10$$

Iteración: $x^{(i+1)} = x^{(i)} - \alpha * (2x^{(i)} - 10)$

$\alpha = 0,5$	converge en un paso
x	Y(x)
0	0
5	-25
5	-25
5	-25

$\alpha = 0,6$	converge de a poco
x	Y(x)
0	0
6	-24
4,8	-24,96
5,04	-24,9984

$\alpha = 1$	itera, nunca converge
x	Y(x)
0	0
10	0
0	0
10	0

$\alpha = 2$	diverge
x	Y(x)
0	0
20	200
-40	2000
140	18200

Ejercicio 3

Estados: Supongamos que numeramos de forma única todas las casillas del tablero, incluyendo las de salida y de llegada. Supongamos también que numeramos todas las fichas del tablero, del 1 al 16 (4 de cada color). En ese caso, el estado queda determinado por la casilla en la que se encuentra la ficha i , C_i , para todo i . También incluimos en el estado el número arrojado por el dado.

Acciones: cada agente tiene que decidir en su turno *luego* de conocer el número resultante del dado. Por lo tanto, la acción a realizar consta de elegir una ficha 1..4 de entre las de su color para mover. Es decir, hay 4 acciones, una por cada ficha a elegir para mover.

Función de transición: dado un número del dado y una ficha elegida, la función de transición queda descrita por:

- mover la ficha elegida el número de casillas estipulado si esta ficha puede hacerlo
- sacar a la ficha del punto de salida si el número lo permite (6)
- no cambiar nada de lo contrario


Esto último puede significar una variante con respecto a la dinámica más natural del ludo, donde no se permite al jugador elegir una ficha que no va a poder mover. El modelado planteado, sin embargo, permite un conjunto fijo de acciones.

Función de recompensa: la función de recompensa puede definirse tan simple como:

- 1 si el jugador gana (todas las fichas en la llegada)
- 0 si no

Ejercicio 4

Para converger al clustering deseado, se puede elegir la figura de la izquierda. Para converger a otro clustering, la de la derecha:



En el primer caso, los puntos son los centros de los puntos de cada clúster deseado. El algoritmo ejecutará la primera iteración, asignando a cada punto el conjunto de puntos de su clúster y dejando idénticas las coordenadas de los centros. En la siguiente iteración la asignación no cambiará, y el algoritmo convergerá a la solución deseada.

En el segundo caso, los puntos también son el centro de las nubes de puntos más cercanos a ellos. Por lo tanto, el flujo de ejecución será similar, pero asignando al azul los 8 puntos más a la izquierda, y al rojo los 8 más a la derecha, convergiendo a una solución no deseada.

Ejercicio 5

a) La función de hipótesis de la regresión logística es:

$$h_{\theta}(x) = \sigma(\theta^T x)$$

siendo

$$\theta^T x$$

la combinación lineal de los parámetros (igual que en la regresión lineal), a lo que se le aplica la función sigmoide:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

para transformar sus valores al rango (0,1).

Para clasificar nuevas instancias agregamos una frontera de decisión:

Si

$$h_{\theta}(x) \geq 0.5 \quad \text{predice la clase positiva (y=1)}$$

Si

$$h_{\theta}(x) < 0.5 \quad \text{predice la clase negativa (y=0)}$$

b) La regresión logística es un clasificador probabilístico porque no solamente intenta predecir la clase correcta para una nueva instancia dada, sino que además estima la probabilidad de que la instancia pertenezca a dicha clase. La función de hipótesis

$$h_{\theta}(x) = \sigma(\theta^T x)$$

se interpreta como la siguiente probabilidad condicional:

$$P(y = 1 \mid x; \theta)$$

que es la probabilidad de que la instancia "x" sea clasificada en la clase "y" utilizando los parámetros theta.

$$h_{\theta}(x) = P(y = 1 \mid x; \theta)$$

Por ejemplo, si

$$h_{\theta}(x) = 0.8$$

se interpreta como una probabilidad del 80% de que "x" pertenezca a la clase positiva (y=1).

c) Si tenemos una instancia x que debe ser clasificada como y, y su predicción da $\hat{y} = H(x)$ entonces su contribución al error se mide como: $\hat{y}^y (1-\hat{y})^{1-y}$. Se puede verificar que esa forma es correcta calculando su valor para todos los casos posibles:

y	0	1
$\hat{y}$		
0	1	0
1	0	1

En la tabla se puede ver que si la clasificación es correcta entonces su contribución es 1, mientras que si la clasificación es incorrecta entonces su contribución es 0.

Dado que la función de costos debe ser minimizada tomaremos el negativo de dichos valores, y, aplicando el logaritmo para simplificar cuentas, llegamos a la función de costos de la regresión logística:

$$p(y|x) = \hat{y}^y (1 - \hat{y})^{1-y}$$

$$L_{CE}(\hat{y}, y) = -\log p(y|x)$$

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m L_{CE}(h_{\theta}(x^{(i)}), y^{(i)})$$

d) La regresión logística multiclase se implementa utilizando el método “1-versus-rest”. Si queremos clasificar en “n” clases (0,1,...n) lo que hacemos es dividir el problema original (multiclase) en “n+1” problemas de clasificación binaria donde tendremos tendremos en el problema “i” la función de hipótesis

$$h_{\theta}^{(i)}$$

que nos separa las instancias de clase “i” de todo el resto de las instancias.

Luego, dado una nueva instancia “x” prediremos la clase “i” para la que el valor de

$$h_{\theta}^{(i)}(x)$$

es máximo.

Ejercicio 6

a) Como el conjunto de atributos no es vacío y el conjunto de entrenamiento no es homogéneo, debo seleccionar un atributo. Busco aquel atributo T que maximice la ganancia $G(S,T)$, o sea, minimice la entropía relativa del conjunto: $\sum_{v \in \text{Val}(T)} (|S_v|/|S|) \text{Entropía}(S_v)$.

Atributo Color:

$$\begin{aligned} &= 2/5 \text{Entropía}(S_{C=\text{amarilla}}) + 3/5 \text{Entropía}(S_{C=\text{blanca}}) \\ &= 2/5 [-1/2 \log 1/2 - 1/2 \log 1/2] + 3/5 [-2/3 \log 2/3 - 1/3 \log 1/3] \\ &= 2/5 \cdot 1 + 3/5 \cdot 0,91 = 0,95 \end{aligned}$$

Atributo Gramaje:

$$\begin{aligned} &= 2/5 \text{Entropía}(S_{G=\text{bajo}}) + 2/5 \text{Entropía}(S_{G=\text{alto}}) + 1/5 \text{Entropía}(S_{G=\text{mediano}}) \\ &= 2/5 [-1/2 \log 1/2 - 1/2 \log 1/2] + 2/5 [-1/2 \log 1/2 - 1/2 \log 1/2] + 1/5 [-1/1 \log 1/1 - 0/1 \log 0/1] \\ &= 2/5 \cdot 1 + 2/5 \cdot 1 + 1/5 \cdot 0 = 4/5 = 0,80 \end{aligned}$$

Atributo Hojas:

$$\begin{aligned} &= 2/5 \text{Entropía}(S_{H=\text{muchas}}) + 3/5 \text{Entropía}(S_{H=\text{pocas}}) \\ &= 2/5 [-1/2 \log 1/2 - 1/2 \log 1/2] + 3/5 [-2/3 \log 2/3 - 1/3 \log 1/3] \\ &= 2/5 \cdot 1 + 3/5 \cdot 0,91 = 0,95 \end{aligned}$$

Atributo Reciclable:

$$\begin{aligned} &= 2/5 \text{Entropía}(S_{R=\text{no}}) + 3/5 \text{Entropía}(S_{R=\text{si}}) \\ &= 2/5 [-1/2 \log 1/2 - 1/2 \log 1/2] + 3/5 [-2/3 \log 2/3 - 1/3 \log 1/3] \\ &= 2/5 \cdot 1 + 3/5 \cdot 0,91 = 0,95 \end{aligned}$$

Se elige, entonces, al atributo **Gramaje** y se genera una rama por cada uno de sus posibles valores:

- Gramaje = alto

Se llama recursivamente con los atributos {Color, Hojas, Reciclable} y los ejemplos {#2, #3}.

Como el conjunto es heterogéneo y hay atributos se debe seleccionar uno. Repitiendo los cálculos:

$$\begin{aligned} G(\{ \#2, \#3 \}, \text{Hojas}) &= 0 \\ G(\{ \#2, \#3 \}, \text{Color}) &= G(\{ \#2, \#3 \}, \text{Reciclable}) = 1 \end{aligned}$$

El atributo para este nodo es **Color** y se genera una rama para cada posible valor:

- Color = blanca, llamada recursiva ID3({#3}, {Hojas, Reciclable})
- Color = amarilla, llamada recursiva ID3({#2}, {Hojas, Reciclable})

- Gramaje = mediano

Se llama recursivamente ID3(A={Color, Hojas, Reciclable}, D={#5}).

Como todos los ejemplos tienen un mismo valor objetivo, se genera una hoja con el valor **Sí**.

- Gramaje = bajo

Se llama recursivamente ID3(A={Color, Hojas, Reciclable}, D={#1, #4}).

Como el conjunto es heterogéneo y hay atributos se debe seleccionar uno.

Repitiendo los cálculos:

$$G(\{ \#1, \#4 \}, \text{Hojas}) = 0$$

$$G(\{ \#1, \#4 \}, \text{Color}) = G(\{ \#1, \#4 \}, \text{Reciclable}) = 1$$

El atributo para este nodo es **Reciclable** y se genera una rama para cada posible valor:

- Reciclable = sí, llamada recursiva ID3({#1}, {Hojas, Color})
- Reciclable = no, llamada recursiva ID3({#4}, {Hojas, Color})

$$b) \text{NB}(\langle a_1, a_2, a_3, a_4 \rangle) = \operatorname{argmax}_{v \in \{\text{sí}, \text{no}\}} P(\text{valor}=v) \prod P(\text{atributo}_i=a_i \mid \text{valor}=v)$$

Se estiman todas las probabilidades necesarias:

$$P(\text{sí}) = 3/5$$

$$P(\text{no}) = 2/5$$

$$P(C=\text{blanca} \mid \text{sí}) = 2/3 \quad P(C=\text{blanca} \mid \text{no}) = 1/2$$

$$P(C=\text{amarilla} \mid \text{sí}) = 1/3 \quad P(C=\text{amarilla} \mid \text{no}) = 1/2$$

$$P(G=\text{bajo} \mid \text{sí}) = 1/3 \quad P(G=\text{bajo} \mid \text{no}) = 1/2$$

$$P(G=\text{mediano} \mid \text{sí}) = 1/3 \quad P(G=\text{mediano} \mid \text{no}) = 0$$

$$P(G=\text{alto} \mid \text{sí}) = 1/3 \quad P(G=\text{alto} \mid \text{no}) = 1/2$$

$$P(H=\text{muchas} \mid \text{sí}) = 1/3 \quad P(H=\text{muchas} \mid \text{no}) = 1/2$$

$$P(H=\text{pocas} \mid \text{sí}) = 2/3 \quad P(H=\text{pocas} \mid \text{no}) = 1/2$$

$$P(R=\text{sí} \mid \text{sí}) = 2/3 \quad P(R=\text{sí} \mid \text{no}) = 1/2$$

$$P(R=\text{no} \mid \text{sí}) = 1/3 \quad P(R=\text{no} \mid \text{no}) = 1/2$$

c) Considero L_2 para la distancia entre instancias y $(1 - \delta_k)$ para los atributos. El modelo de 3-NN tomará las 3 instancias más cercanas y dará por salida la clase más común entre ellas.

d)

1. ID3(#6) = sí, en la raíz se pregunta por gramaje y, por ser mediano, termina en una hoja sí.

2. CBS(#6) = sí, porque es el argumento que maximiza la productoria:

$$P(\text{sí}).P(C=\text{blanca} \mid \text{sí}).P(G=\text{mediano} \mid \text{sí}).P(H=\text{muchas} \mid \text{sí}).P(R=\text{sí} \mid \text{sí}) \\ = 3/5.2/3.1/3.2/3 = 4/135$$

$$P(\text{no}).P(C=\text{blanca} \mid \text{no}).P(G=\text{mediano} \mid \text{no}).P(H=\text{muchas} \mid \text{no}).P(R=\text{sí} \mid \text{no}) \\ = 2/5.1/2.0.1/2.1/2 = 0$$

3. 3-NN(#6) = sí, por ser las instancias más cercanas #1-sí, #3-no y #5-sí.

#	Color	Gramaje	Hojas	Reciclable	Valor	Dist. ²
1	blanca	bajo	muchas	sí	Sí	1
2	amarilla	alto	pocas	no	Sí	4
3	blanca	alto	pocas	sí	No	2
4	amarilla	bajo	muchas	no	No	3
5	blanca	mediano	pocas	sí	Sí	1

e) Matriz de confusión:

	M(x)=Sí	M(x)=No
y=Sí	3	0
y=No	1	1

$$\text{Acierto} = \# \text{ correctas} / \# \text{ total} = 4/5 = 0.8$$

$$P_{\text{sí}} = \# \text{ sí correctas} / \# \text{ clasificadas sí} = 3/4 = 0.75$$

$$R_{\text{sí}} = \# \text{ sí correctas} / \# \text{ total sí} = 3/3 = 1$$

$$P_{\text{no}} = \# \text{ no correctas} / \# \text{ clasificadas no} = 1/1 = 1$$

$$R_{\text{no}} = \# \text{ no correctas} / \# \text{ total no} = 1/2 = 0.5$$